

README

1. Contexto del proyecto

Las campañas se realizaron mediante contactos telefónicos directos. A menudo, fue necesario realizar múltiples llamadas a un mismo cliente para obtener una respuesta definitiva sobre la suscripción del producto.

Para abordar este análisis de manera estructurada, hemos categorizado las variables del archivo CVS principal en tres grupos principales tras una investigación previa sobre el contexto bancario:

- **Datos del cliente:** Información demográfica y financiera personal.
- **Datos de la llamada/campaña:** Detalles técnicos de la interacción actual y resultados de campañas previas.
- **Contexto socioeconómico:** Indicadores macroeconómicos del país en el momento del contacto.

La segunda fuente de datos se trata de un archivo Excel con información demográfica y de comportamiento. Este archivo está organizado en tres hojas de trabajo, clasificando a los clientes según el año en que se unieron a la institución.

2. Diccionario de datos

A continuación, se detallan las columnas del dataset principal:

age	Edad del cliente.
job / marital / education	Profesión, estado civil y nivel educativo.
default / housing / loan	Indicadores de historial de impagos, hipoteca o préstamos personales.
contact	Método de contacto con el cliente
duration (last_call_duration)	Duración de la última llamada.
campaign (campaign_contacts)	Número de contactos con este cliente realizados durante la campaña actual.
pdays (days_since_last_contact)	Número de días que han pasado desde el último contacto con este cliente en la campaña actual.
previous (previous_campaigns_contacts)	Número de contactos en campañas anteriores a la actual.
poutcome (last_outcome_success)	Resultado de la campaña anterior.

emp.var.rate / euribor3m	Indicadores económicos (Tasa de empleo y Euribor a 3 meses).
cons.price.idx / cons.conf.idx	Índices de precios y de confianza del consumidor.
y	Target: Indica si el cliente suscribió el producto (Sí/No).
latitude / longitude	Localización de la última llamada realizada.
id_	PK: Identificador único del llamada.

Y las columnas del dataset complementario:

ID	Identificador único del cliente (Clave de unión).
Income	Ingreso anual del cliente.
Kidhome / Teenhome	Número de niños y adolescentes en el hogar.
Dt_Customer	Fecha de alta como cliente en la entidad.
NumWebVisitsMonth	Promedio de visitas mensuales al sitio web de la empresa.

3. Transformación y limpieza de datos

El proceso de preparación de los datos se dividió en tres fases:

3.1. Análisis y Contextualización

Para dar sentido a las variables, se realizó una investigación externa sobre el contexto bancario, permitiendo agrupar la información del archivo CVS en tres pilares: **Información básica del cliente**, **situación económica del país** y **métricas de la llamada**. Por otro lado, el archivo Excel complementa la **información del cliente y su comportamiento**.

A continuación se comentan los datos más específicos del proyecto que coinciden con categorías de indicadores macroeconómicos:

- 'euribor3m' (Tasa Euribor a 3 meses). Es el tipo de interés al que los bancos europeos se prestan dinero entre sí. Si es alto, los bancos ofrecen más beneficios al cliente. Rango entre 0,634 y 5,045.
- 'emp.var.rate' (Tasa de variación del empleo). Indica si el empleo crece o decrece. Si hay más empleo, la gente tiene mas capacidad de ahorro y es más probable que se suscriban a productos de estalvio. Rango entre -3,4 y 1,4.
- 'cons.price.idx' (IPC). Mide la inflación. Si es alta, el dinero pierde valor y la gente suele proteger su dinero en depósitos. Rango entre 92,201 y 94,767.

- 'cons.conf.idx' (Índice de confianza al consumidor). Mide lo optimistas que se sienten los ciudadanos respecto a su futuro financiero. Rango entre -50,8 y -26,9

3.2. Limpieza de los Datos del CSV

Al revisar el archivo CSV original, se observó que la calidad de los datos no era óptima. Las columnas **age**, **default** y **euribor3m** presentaban una cantidad considerable de valores nulos, mientras que el resto de las variables estaban completas. Aunque no detectamos filas duplicadas, la limpieza de cada columna se abordó de forma específica:

Para las variables generales, se realizaron ajustes rápidos como la corrección de errores ortográficos, el cambio de tipos de datos, la estandarización de minúsculas y el renombrado de columnas para que fueran más fáciles de entender.

En el caso de las columnas con muchos nulos, seguimos esta estrategia:

Columna 'age'

Como la edad no sigue una distribución normal (está sesgada), decidimos no usar la media. En su lugar, buscamos una variable relacionada y elegimos el trabajo 'job'. Tras limpiar los outliers, rellenamos los nulos de 'age' utilizando la mediana de edad de cada profesión. Si después de esto aún quedaba algún nulo (porque el trabajo también era desconocido), aplicamos la mediana general de todo el dataset.

Columna 'default'

Primero intenté ver si el hecho de tener deudas dependía de tener hipoteca ('housing') o préstamos personales ('loan'). Al no encontrar una relación lógica o clara, descartamos ese camino. Como la mayoría de los datos se concentraban en una sola opción y no queríamos "inventar" información que sesgara el análisis, decidimos marcar los nulos con un -1. Así los mantenemos identificados sin alterar los resultados.

Columna 'euribor3m'

Aquí realizamos un análisis profundo para intentar salvar la columna. Intentamos imputar los valores nulos buscando registros del mismo día en ubicaciones cercanas (latitud y longitud similares). Descubrimos que los datos no eran consistentes; en un mismo día y lugar, el Euribor variaba drásticamente. Al confirmar que los valores de esta columna no eran fiables, decidimos **no utilizarla en el análisis**. Aun así, dejamos el código preparado por si en el futuro se trabajara con un dataset corregido.

3.3. Limpieza de los Datos del Excel

A diferencia del CSV, el tratamiento de los archivos de Excel fue mucho más directo debido a que el formato era impecable. Los datos ya estaban limpios, sin valores nulos y con los tipos de datos correctos. Fusionamos las tres tablas en un único bloque. Como la información del año ya estaba presente en una columna específica, no fue necesario conservar el origen del archivo. Finalmente, se reiniciaron los índices, ya que no aportaban valor informativo al conjunto.

3.4. Tratamiento de Duplicados y Merge

Durante el análisis del archivo CSV, identificamos filas que compartían casi toda la información del cliente, variando únicamente el ID de la llamada y las coordenadas geográficas (latitud y longitud).

Todo indicaba que se trataba de múltiples llamadas al mismo cliente; sin embargo, al tener IDs distintos y registrarse en ubicaciones diferentes, no podían considerarse duplicados técnicos.

Ante la duda de si estos registros representaban intentos independientes en momentos diferentes o parte de una misma gestión, decidimos mantenerlos. Eliminarlos sin una variable de tiempo exacta (hora) o un histórico más detallado nos habría hecho perder información valiosa sobre la insistencia de las campañas comerciales. Al profundizar en el análisis, confirmamos que estos registros estaban asociados a clientes distintos mediante su ID único, lo que validó nuestra decisión de conservarlos.

Para finalizar la limpieza, realizamos la unión de las dos tablas resultantes mediante un **Left Join**, utilizando el ID como llave de enlace. Analizamos la correspondencia entre ambos datasets y observamos que menos del 1% de las filas de la tabla de llamadas no tenían una fila correspondiente en la tabla secundaria. Además, comprobamos que todos los IDs del segundo dataset estaban presentes en el primero. Esta alta coincidencia nos permitió asegurar que la pérdida de información era prácticamente nula, obteniendo así un dataset final robusto y listo para el modelado.

4. Análisis descriptivo

El objetivo principal de este análisis es identificar el perfil de cliente propenso a suscribir un producto o servicio, así como entender qué factores externos influyen en esta decisión. Como punto de partida, realizamos un análisis numérico de la variable objetivo **‘y’** en relación con el resto de variables del dataset.

4.1. Análisis descriptivo de la muestra (Univariante)

Para entender la composición de la cartera de clientes del banco, se han analizado las variables de forma individual mediante histogramas y gráficos de barras, obteniendo las siguientes conclusiones sobre nuestro perfil de cliente predominante:

- **Edad (age):** Se observa una distribución con un crecimiento rápido entre los 20 y 30 años, alcanzando su **máximo volumen en la franja de los 30 a 40 años**, para luego decrecer progresivamente hacia las edades más avanzadas.
- **Ocupación (job):** La masa crítica de clientes se concentra en tres categorías principales: **administrative, blue-collar y technician**, que representan la gran mayoría de la muestra.
- **Estado Civil (marital):** Existe una clara predominancia de clientes **casados**, que suponen aproximadamente el 50% del total de la base de datos.
- **Nivel Educativo (education):** La formación de los clientes es mayoritariamente media-alta, destacando tres grupos: **university degree, high school y basic 9y**.
- **Ingresos:** Tras el análisis, se determina que esta variable no aporta información diferencial o relevante para la caracterización de la muestra en este modelo.

4.2. Análisis de Determinantes de Éxito (Bivariante)

Para contextualizar los resultados, primero analizamos la distribución de la variable objetivo. Observamos que el dataset está desbalanceado: un 88,75% de los registros corresponden a un

resultado negativo ('False') y un 11,25% a un resultado positivo ('True'). Este último porcentaje será nuestra referencia para comparar el éxito en los diferentes segmentos.

Análisis por perfil de cliente:

- **Edad ('age'):** La receptividad no es lineal. Los extremos son los más predispuestos: los menores de 18 años y los mayores de 60 presentan tasas de suscripción muy superiores a la media. Asimismo, el grupo de entre 18 y 29 años muestra un rendimiento por encima del promedio general.
- **Ocupación ('job'):** Los perfiles más rentables son administrativos, jubilados, estudiantes y desempleados. En el lado opuesto, los sectores con menor tasa de éxito son entrepreneurs (emprendedores), services y blue-collars (trabajadores manuales).
- **Estado Civil ('marital'):** Los clientes solteros presentan una ligera ventaja en la tasa de éxito, aunque la diferencia no se considera estadísticamente determinante.
- **Nivel Educativo ('education'):** Es el hallazgo más sorprendente; el grupo analfabeto (illiterate) tiene una tasa de éxito del 22,22%, duplicando la media general. Por el contrario, el grupo basic 9y es el más resistente, con un 92,23% de respuestas negativas.

Conclusión del perfil: El "cliente ideal" es una persona joven o jubilada, con perfil administrativo o estudiante.

Análisis por método de contacto, hogar y interacción con la web:

- **Canal de comunicación ('contact'):** Existe una brecha crítica de eficacia. El contacto vía móvil (cellular) es drásticamente más efectivo que el teléfono fijo.
- **Estructura familiar y web ('Kidhome', 'Teenhome', 'NumWebVisitsMonth'):** Variables como la presencia de niños o adolescentes en casa o la frecuencia de visitas a la web no muestran un impacto relevante en la decisión final, comportándose como variables neutrales.

Análisis de la campaña:

- **Éxito en la campaña anterior ('last_outcome_success'):** Es la variable más predictiva. Si el cliente ya aceptó un producto anteriormente, la probabilidad de éxito actual sube al 34,57% (el triple de la media).
- **Duración de la última llamada ('last_call_duration'):** Los datos muestran que a medida que aumenta la duración de la última llamada, el porcentaje de éxito en la suscripción crece de manera proporcional.
- **Esfuerzo comercial ('campaign_contacts'):** Existe un punto de saturación claro. A partir de la 7ª llamada, la probabilidad de éxito cae por debajo del 7%, lo que sugiere que insistir más allá de este punto deja de ser rentable.
- **Contactos en campañas anteriores ('previous_campaigns_contacts'):** Se observa un incremento drástico en la probabilidad de éxito cuando el cliente ha sido contactado en campañas previas.
- **Días desde el último contacto ('days_since_last_contact'):** Se observa que la insistencia controlada es efectiva. Los contactos realizados en el día 0 (mismo día) presentan una tasa de

conversión superior al promedio. A partir del segundo día, la tasa de éxito se mantiene estable, lo que sugiere que el interés del cliente no decae inmediatamente.

Análisis de la situación económica:

- **Tasa de empleo ('emp.var.rate'):** Existe una relación inversa. Cuando la tasa es positiva (crecimiento de empleo), el éxito es bajo. Por el contrario, el éxito aumenta en periodos con tasas negativas.
- **Inflación ('cons.price.idx'):** El porcentaje de éxito es máximo en los valores más altos del índice, donde la conversión roza el 50%, y también repunta notablemente en la franja más baja.
- **Índice de confianza ('cons.conf.idx'):** Las tasas de conversión más altas se encuentran en los dos grupos con mayor optimismo y, simultáneamente, en el grupo con el índice de confianza más bajo.
- **Índice euribor ('euribor3m'):** A pesar de los problemas de consistencia de este dato, la tendencia muestra que por encima de un Euribor 2, la tasa de éxito es prácticamente inexistente.

Conclusión económica: El producto tiene un comportamiento "anticíclico"; se vende mejor cuando el empleo flaquea o el Euribor es bajo.

4.2.1. Definición de Perfiles de Éxito

Tras el análisis bivariente y con el objetivo de encontrar los grupos de cliente que maximizan la tasa de éxito debemos intersecar variables del análisis bivariente. A continuación se identifican algunos perfiles con mayor potencial para la suscripción al producto.

Perfil A: 'poutcome_success' y 'contact'

Al contrastar los determinantes de éxito 'poutcome_success' = 1 y 'contact' = celular, observamos que aunque el contacto vía celular supera significativamente al teléfono fijo, el éxito en la campaña anterior 'poutcome_success' se consolida como el principal maximizador de la tasa de conversión. Los datos confirman que un resultado positivo previo es el indicador más fiable para predecir una nueva suscripción.

Perfil B: 'job' y 'emp.var.rate'

Tomando los clientes retirados o desempleados y analizando la tasa de éxito en función de la tasa de empleo, observamos que existe una correlación inversa muy marcada, donde el rendimiento de la campaña se dispara precisamente en los periodos de mayor contracción laboral. Este segmento específico demuestra una resiliencia superior a la media global, alcanzando niveles de conversión máximos cuando las tasas de variación del empleo son negativas.

Perfil C: 'poutcome_success' y 'emp.var.rate'

Como hemos visto que ambas variables ('poutcome_success' = 1 y 'emp.var.rate' < 0) maximizan la tasa de éxito, vamos a analizar que pasa si cruzamos ambas variables.

Al cruzar ambas variables, se confirma que la combinación de un resultado positivo previo ('poutcome_success' = 1) y un entorno de desempleo (emp.var.rate < 0) potencia drásticamente la efectividad de la campaña. Como se observa en la matriz de decisión, el éxito de la campaña

anterior actúa como un catalizador que eleva las probabilidades de conversión por encima del 60% en contextos de fuerte contracción económica y en escenarios de estabilidad neutra.

Perfil D: ‘age’, ‘marital’, ‘job’ y ‘contact’

Contrastando un perfil joven y soltero con un método de contacto eficiente, obtenemos que el uso del teléfono móvil es la clave para conectar con este grupo, logrando casi llegar a triplicar la tasa de éxitos sobre el resto de perfiles.


Perfil E: ‘education’ y ‘last_call_duration’

El análisis de los datos indica que el segmento con nivel educativo analfabeto alcanza una alta eficiencia mediante la atención personalizada. En llamadas de larga duración, este grupo registra una tasa de éxito superior al **33%**, una cifra que contrasta con el **11.3%** del promedio global.


5. Visualización de los datos

Durante todo el análisis se han considerado visualizaciones para hacer más fácil la extracción de conclusiones, a continuación veremos algunos casos.


Se encuentran comentados en el fichero de jupyter.





Tendencia de Suscripciones por Edad




Éxito Perfil B vs. Media Global por Tasa de Empleo






Perfil D: Impacto del Canal en Jóvenes Solteros



Perfil E: Éxito en Colectivo "Illiterate" según Duración de Llamada



6. Conclusiones del análisis

Tras el análisis se extraen las siguientes conclusiones fundamentales:

- **Eficacia de la Campaña Previa:** El éxito en una campaña anterior es la variable más predictiva del rendimiento actual, elevando la probabilidad de suscripción al 34,57%, lo que supone el triple de la media general.
- **Comportamiento Anticíclico:** El producto financiero muestra una mayor tasa de conversión en periodos de contracción económica, especialmente cuando la tasa de variación del empleo es negativa o el Euribor se mantiene bajo.
- **Optimización del Contacto:** Existe una brecha crítica de eficacia según el canal; el contacto vía móvil (cellular) es drásticamente más efectivo que el teléfono fijo.
- **Punto de Saturación Comercial:** Se ha identificado un límite de eficiencia en la insistencia; a partir de la séptima llamada al mismo cliente, la probabilidad de éxito cae por debajo del 7%, dejando de ser rentable el esfuerzo comercial.
- **Perfil de Cliente de Alta Conversión:** El "cliente ideal" se concentra en los extremos de edad (menores de 29 años y mayores de 60) con perfiles profesionales administrativos, jubilados o estudiantes.
- **Influencia del Nivel Educativo:** Aunque el grupo illiterate presenta la mayor tasa de conversión individual (22,22%), se debe notar que representa una masa crítica mínima dentro del total de la muestra. En contraste, el grupo *basic 9y* es el más resistente al producto.
- **Variables Neutras:** Factores como el nivel de ingresos, la presencia de niños en el hogar o la frecuencia de visitas a la web no muestran un impacto relevante en la decisión final de suscripción.